

Projet Deep Learning

IA201: Projet en Machine Learning Supervisée

Filière Télécommunications – Semestre 8

Élèves:

Shakty ROBERT

Angel-Rémy TABARY

Encadrants:

Yannick BERTHOUMIEU

Pedro CASTRO CORTES C COUTINHO

Introduction


Ce projet Deep Learning vise à évaluer **plusieurs stratégies CNN** sur deux jeux de données distincts.

Il se divise en deux parties :

- **Partie 1** : Classification binaire de mélanomes
- **Partie 2** : Classification multi-classes de maladies de plantes

Partie 1

Modèle à 2 sorties - Base de données “Melanoma Cancer”



Modèle à 2 sorties - Base de données “Melanoma Cancer”

But : classer **deux types** de mélanomes (tumeur de la peau)

Sorties possibles : Malin ou Bénin

Pour cela, nous utilisons le dataset **Kaggle** “Melanoma Cancer Image Dataset” fourni.

- **Training** :
 - Malin : 6300 images environ
 - Bénin : 6000 images environ
- **Test**
 - Malin : 1000 images
 - Bénin : 1000 images

Modèle à 2 sorties - Base de données “Melanoma Cancer”

Rappel des approches a utilisées :

Première approche : **CNN from Scratch**

Deuxième approche : Transfer Learning avec **gel complet**

Troisième approche : Transfer learning avec **Fine-Tuning**

➤ Tous les temps d'entraînement indiqués correspondent à une exécution sur Google Colab (en utilisant le GPU T4).

Première approche : CNN from Scratch

1. Implémentation d'un **CNN** à 3 couches de convolution

Parcours de **20 epoch** avec un **batch size de 64**. Approche pas assez profonde.

➤ Fonction de perte stagnant entre **0.3** et **0.4** (faible accuracy)

2. Passage à **5 couches** mais accuracy encore trop faible
3. Ajout d'un **Batch Normalization** + **learning rate** plus élevé
4. Gradient stochastique changé en AdamW (pour plus de rapidité et de précision)

Première approche : CNN from Scratch







Figure 1: Schéma du CNN obtenu
Entrée : 128x128x3
Sortie : 2 classes

Résultats obtenus (base d'entraînement)



Résultats obtenus (base de test)



➤ Reconnaît bien les grains de beauté non dangereux : **946 sur 1 000** correctement identifiés

➤ Pour les cas dangereux, il en rate **135 sur 1 000** (mélanomes que le modèle croit bénins)

Problématique car on risque de passer à côté d'un vrai cancer

Deuxième approche : Transfer Learning avec gel complet

Modèle de base : ResNet-18 pré-entraîné sur la bibliothèque ImageNet

-> 18 couches (convolutions + blocs résiduels “skip connections”)

Apprend des filtres génériques (bords, textures, formes...)



Deuxième approche : Transfer Learning avec gel complet

Passage à un **batch size de 128** et à **25 epoch** parcourues

Principe :

- On gèle toutes les couches convolutionnelles
- On ne forme que la tête adaptée au binaire (soit bénin, soit malin)

Avantage : Démarrage rapide et permet d'établir un modèle solide avant de passer à une approche fine-tuning

Deuxième approche : Transfer Learning avec gel complet




Figure 2: Transfer Learning gelé : seules les couches colorées en bleu (ici la nouvelle tête FC) sont entraînables







Figure 3: BasicBlock d'une layer de ResNet-18 : deux convolutions 3 x 3 + BN/ReLU et une connexion résiduelle (skip)

Résultats obtenus (base d'entraînement)



Résultats obtenus (base de test)



- Résultats **corrects** mais **moins bon** qu'avec le CNN from Scratch
- Grains de beauté non dangereux : **933 sur 1 000** correctement identifiés (946 pour le CNN from scratch)
- Mélanomes malins ratés : **181 sur 1 000** (135 pour le CNN from scratch)

Troisième approche : Transfer Learning avec Fine-Tuning






Figure 4: Fine-Tuning partiel : on décongèle et entraîne uniquement les layers 3 & 4 ainsi que la tête FC


- Pourquoi uniquement **Layer 3** et **4** ?
 - Couches basses (Conv1→Layer 2) capturent des filtres généraux (bords, textures)
 - Couches profondes (Layer 3→Layer 4) apprennent des caractéristiques spécifiques au mélanome

Objectif : meilleure accuracy (et moins de faux négatifs)

Résultats obtenus - Fine-Tuning (base d'entraînement)



Résultats obtenus - Fine-Tuning (base de test)



- Très bons résultats
 - Meilleur que le CNN from Scratch
 - Meilleur que le Transfer Learning avec gel complet
- Loss en dessous des 0,1

Tableau comparatif des approches utilisées

	CNN from Scratch	Transfer learning avec gel complet	Transfert learning avec Fine-Tuning
Accuracy (sur 5 tests)	90,41%	87,50%	93,54%
Temps d'apprentissage (en utilisant le GPU T4)	5 min sur 20 epochs	7 min sur 25 epochs	8 min sur 25 epochs



Modèle le plus performant

Dernière idée : Transfer learning avec Fine-Tuning complet

Peut-on dégeler les layer 1 et 2 également pour avoir de meilleurs résultats ?

	Transfert learning avec Fine-Tuning	Transfer learning avec Fine-Tuning complet
Accuracy (sur 5 tests)	93,54%	93,08%
Temps d'apprentissage (en utilisant le GPU T4)	8 min	9 min



Non ! Plus long et moins bonne accuracy

Partie 2

Modèle à 38 sorties - Base de données “Plant Diseases”



Modèle à 38 sorties - Base de données “Plant Diseases”

But : Classifier une image de feuille en 38 catégories :

- maladies spécifiques (ex : Apple___Apple_scab)
- ou état sain (ex : Tomato___healthy)

Exemples de sorties possibles

- Apple___Apple_scab
- Grape___Black_rot
- Potato___Late_blight
- Tomato___Leaf_Mold
- Tomato___healthy

Modèle à 38 sorties - Base de données “Plant Diseases”

Pour cela, nous utilisons le dataset **Kaggle** “New Plant Diseases Dataset” fourni :

- **Training** : 56 000 images
- **Validation** : 17 400 images
- **Test** : 14 000 images

Différence avec le modèle "Cancer" : Ici, nous utilisons également un ensemble de validation afin de détecter le surapprentissage

Approches testées identiques :

CNN from Scratch, Transfer learning gelé, Transfer learning avec Fine-Tuning

Première approche : CNN from Scratch

Utilisation de la même architecture que pour le modèle "Cancer" :

- 4 couches **Conv + BatchNorm + MaxPool + ReLU**




Sortie modifiée : couche FC finale **adaptée à 38 classes**

Passage à un batch size de **128** au lieu de **64** pour le CNN "Cancer".

Validation set utilisé pour :

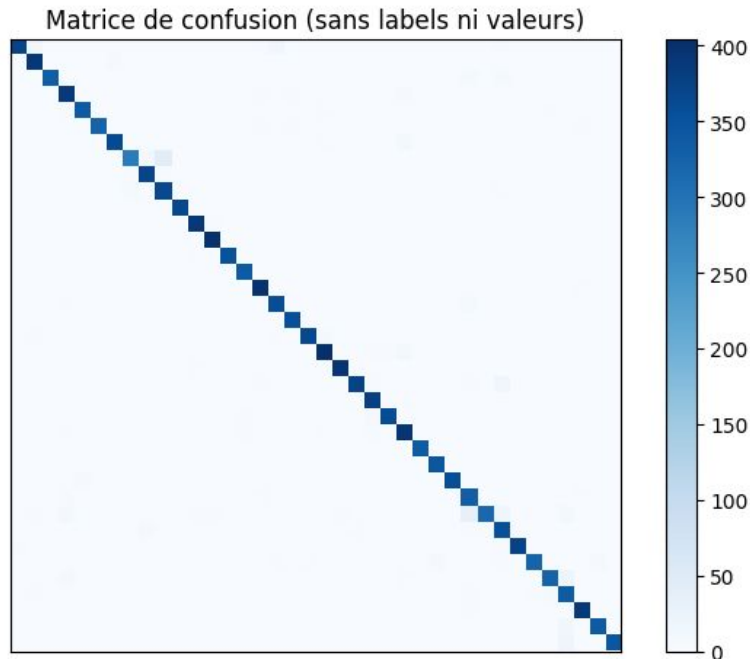
- suivi de la loss de validation
- déclenchement d'un early stopping après **3 epochs** sans amélioration

Première approche : CNN from Scratch



Early stopping à 12 epochs

Première approche : CNN from Scratch



Des résultats très solides pour un CNN from Scratch (Accuracy de **96.75%** sur 5 tests)

Certains labels reconnus avec une précision de 100% e.g. :

Cherry_(including_sour)___healthy : 100%

Corn_(maize)___healthy : 100%

La matrice ci-contre n'affiche pas le nom des **38 classes** pour ne pas alourdir la notation

Première approche : CNN from Scratch

Maïs – Cercospora_leaf_spot Gray_leaf_spot :

→ Précision de 90,3 %, avec 8,1 % des images confondues en Northern_Leaf_Blight.



Ex: 2 images labellisées
Cercospora_leaf_spot Gray Leaf Spot



Ex: 2 images labellisées
Northern Leaf Blight

Deuxième approche : Transfer Learning avec gel complet

- Utilisation du même modèle ResNet18 :
 - On gèle toutes les couches sauf la couche FC de sortie
 - FC de sortie adaptée à 38 classes de sortie








Figure 5: Transfer learning gelé : même principe que pour le CNN “Cancer”

Résultats obtenus (base d'entraînement)



Résultats obtenus (base de test)



Des résultats solides mais moins bons que pour le CNN from Scratch (Accuracy de 88.96% sur 5 tests)

Focus sur les classes “Tomate”

- 11 catégories de maladies/états de tomate
- 7 d’entre elles présentent une accuracy légèrement inférieure au reste




Même problème avec les deux classes
Maïs

Troisième approche - Transfer Learning avec Fine-Tuning


- Même principe que pour le Transfer Learning avec Fine-Tuning du modèle “Cancer” :
 - On gèle toutes les couches sauf les couche appartenant au
 - Layer 3
 - Layer 4
 - FC de sortie

Apprentissage plus long mais meilleure accuracy attendue.

Résultats obtenus - Fine-Tuning (base d'entraînement)



Résultats obtenus - Fine-Tuning (base de test)



Modèle très performant avec une accuracy de plus de 97,91%

- Confusions inverse de l'approche from-scratch :
 - 5,2 % des Northern_Leaf_Blight classées en Gray_leaf_spot (et plus plus le contraire)
- Gain vs CNN from Scratch
 - + 1,16 % d'accuracy globale

Tableau comparatif des approches utilisées

	CNN from Scratch	Transfer learning avec gel complet	Transfert learning avec fine-tuning
Accuracy (sur 5 tests)	96.75%	88,96%	97,91%
Temps d'apprentissage (en utilisant le GPU T4)	27 min pour 12 epochs	23 min pour 12 epochs	11 min pour 4 epochs



Modèle le plus performant

Point de **vigilance** sur les trois modèles:

➤ les classe Maïs Northern_Leaf_Blight et Gray_leaf_spot peuvent être confondues

Conclusion

Transfer Learning + Fine-Tuning (ResNet-18)

→ Meilleure performance sur les deux cas (mélanomes & plantes)

Avantages

- Pas besoin de concevoir un CNN from scratch
- Poids pré-entraînés : gain de temps et de fiabilité

À éviter

Dégeler les premières couches : perte du bénéfice du pré-entraînement